

Universidad Tecnológica Nacional
Facultad Regional Santa Fe

CIENCIA DE DATOS

Trabajo Práctico N°1

Integrantes

Herbel Aldana - aldanaherbell@gmail.com

Soler Lautaro - solerlautaro@gmail.com

Meyer Nahuel - nahuelmeyer16@gmail.com

Oggier Iván - ivanmatiasoggier@hotmail.com

Profesores

Pacchiotti Mauro - mpacchiotti@frsf.utn.edu.ar

Ale Mariel - male@frsf.utn.edu.ar

21 de mayo de 2026

Índice

1. Introducción	1
2. Descripción del conjunto de datos	1
3. Parte 1 - Análisis exploratorio de datos	2
3.1 Medidas de tendencia central	2
3.2 Medidas de dispersión	3
3.3 Distribuciones.....	3
3.4 Proporciones	7
3.5 Relaciones entre variables y gráficos de dispersión	9
3.6 Análisis de correlación	14
4. Parte 2 - Preprocesamiento de datos	16
4.1 Análisis y eliminación de variables irrelevantes.....	16
4.2 Tratamiento de valores faltantes	16
4.3 Detección y tratamiento de valores atípicos	17
4.4 Análisis de correlación para reducción de variables	20
4.5 Procesamiento de variables categóricas	21
4.6 Balance del conjunto de datos	22
4.7 Normalización del conjunto de datos.....	23
5. Parte 2 - Entrenamiento y evaluación de modelos.....	25
5.1 División del conjunto de datos.....	25
5.2 Regresión logística.....	25
Descripción del modelo	25
Hiperparámetro optimizado: C (regularización)	25
Métricas del modelo final (C = 10)	26
Matriz de confusión - Regresión logística	26
5.3 Árbol de decisión.....	27
Descripción del modelo	27

Hiperparámetro optimizado: max_depth	27
Métricas del modelo final (max_depth = 15)	28
Matriz de confusión - Árbol de decisión	28
5.4 Random Forest (modelo ensamblado)	28
Descripción del modelo	28
Configuración del modelo	29
Búsqueda de hiperparámetros: max_depth	29
Parámetros del modelo final (max_depth = 20, n_estimators = 100)	29
Métricas del modelo final (max_depth = 20, n_estimators = 100)	30
Matriz de confusión - Random Forest	31
Importancia de variables	31
6. Comparación de resultados	33
6.1 Selección del mejor modelo	34
7. Conclusiones finales	35

1. Introducción

El presente trabajo práctico tiene como objetivo principal aplicar el flujo de un proyecto de ciencia de datos, desde el análisis exploratorio hasta la evaluación de modelos de aprendizaje automático, sobre un conjunto de datos sintéticos de mantenimiento predictivo industrial.

El dataset contiene registros de sensores de equipos industriales y la variable objetivo indica si el equipo sufrió una falla (“failure”) o no (“normal”). El objetivo es construir modelos capaces de predecir fallas con la mayor sensibilidad posible, ya que en el contexto industrial un fallo no detectado puede resultar en pérdidas económicas significativas o accidentes.

2. Descripción del conjunto de datos

El dataset utilizado es un conjunto de datos sintéticos sobre mantenimiento predictivo industrial. Cada registro representa la lectura de sensores de un equipo en un instante de tiempo determinado. A continuación se describen las variables disponibles:

Variable	Descripción
idx	Índice del registro (identificador único, no predictivo).
parent_device_id	Identificador del dispositivo o lote de origen (no predictivo).
product_type	Tipo de producto fabricado. Categorías: “L”, “M”, “H”.
air_temp [K]	Temperatura ambiente medida en Kelvin. Variable continua.
process_temp [K]	Temperatura del proceso medida en Kelvin. Variable continua.
speed [RPM]	Velocidad de rotación en revoluciones por minuto. Variable entera.
torque [Nm]	Par de torsión aplicado, medido en Newton-metro. Variable continua.
tool_wear [min]	Desgaste de la herramienta en minutos de uso acumulado. Variable entera.
target	Variable objetivo: “normal” (sin falla) o “failure” (falla detectada). Variable binaria.

Tabla 1: Descripción de variables del conjunto de datos.

3. Parte 1 - Análisis exploratorio de datos

3.1 Medidas de tendencia central

Se calcularon media, mediana y moda para cada variable numérica. Los resultados permiten caracterizar el comportamiento típico de cada sensor:

Variable	Media	Mediana	Moda	Observación
air_temp [K]	300,48	300,6	300,7	Media $\approx$ mediana indica una distribución simétrica.
process_temp [K]	310,17	310,32	310,6	Alta consistencia, baja variabilidad.
speed [RPM]	1513,39	1423	1377	Media > mediana indica sesgo derecho (outliers altos).
torque [Nm]	44,96	46,7	35,8	Mediana > media indica leve sesgo izquierdo.
tool_wear [min]	124,92	127	208	Distribución casi uniforme con pico al final.
product_type	—	—	“L”	Categoría más frecuente: tipo “L”.
target	—	—	“failure”	Leve predominancia de la clase “failure”.

Tabla 2: Medidas de tendencia central por variable.

La proximidad entre media y mediana en *air_temp* y *process_temp* indica distribuciones relativamente simétricas. En *speed*, la diferencia entre media (1513,39 RPM) y mediana (1423 RPM) sugiere la presencia de valores altos que desplazan la media, confirmada luego por el análisis de outliers. En *tool_wear*, la distancia entre la mediana (127 min) y la moda (208 min) refleja el pico anómalo de desgaste elevado observado en su distribución, que como se verá más adelante coincide con una mayor concentración de fallas.

3.2 Medidas de dispersión

Las medidas de dispersión cuantifican la variabilidad de cada variable. Una baja dispersión indica que el proceso opera en condiciones controladas, mientras que una alta dispersión puede señalar equipos bajo condiciones diversas o inestables.

Variable	Desv. estándar	Rango	Interpretación	Nivel
air_temp [K]	1,95	9,20	Muy baja dispersión. Temperatura ambiente estable.	Bajo
process_temp [K]	1,33	8,1	Menor dispersión que el aire. Proceso muy consistente.	Bajo
speed [RPM]	313,6	2887	Alta dispersión. Presencia de outliers extremos.	Alto
torque [Nm]	14,23	72,8	Dispersión moderada-alta. Variabilidad operacional.	Medio
tool_wear [min]	70,11	253	Alta dispersión. Amplio rango de condiciones de uso.	Alto

Tabla 3: Medidas de dispersión por variable.

Las variables de *temperatura* presentan dispersiones muy bajas, lo cual es esperable en procesos industriales controlados. En contraste, *speed* muestra el rango más amplio del dataset (2887 RPM), aunque su desviación estándar relativamente baja (313,6) indica que los datos se concentran cerca de la media y los valores extremos son pocos pero muy alejados, confirmando la presencia de outliers puntuales. *tool_wear* presenta alta dispersión real, con registros distribuidos a lo largo de todo su rango. El *torque*, si bien es clasificado como nivel medio, tiene una variabilidad operacional considerable que, como se verá en el análisis de outliers, resulta crítica para la detección de fallas.

3.3 Distribuciones

Se graficaron histogramas para las variables numéricas y gráficos de barras para las variables categóricas. A continuación, se describen los hallazgos más relevantes de cada variable:

air_temp [K]: distribución multimodal con pico principal en ~302 K. La multimodalidad puede reflejar distintas condiciones ambientales o turnos de trabajo.




Figura 1: Distribución de la variable *air_temp* [K].

process_temp [K]: distribución unimodal con sesgo leve a la izquierda. Pico de frecuencia en ~311 K. Pequeña concentración secundaria entre 308-309 K, posiblemente asociada a períodos de arranque del proceso.




Figura 2: Distribución de la variable *process_temp* [K].

speed [RPM]: fuerte concentración en ~1500 RPM con sesgo marcado hacia la derecha. Se identifica un grupo secundario en ~2700 RPM y presencia de valores cercanos a 0 (errores de sensor, tratados posteriormente).




Figura 3: Distribución de la variable speed [RPM].

torque [Nm]: distribución aproximadamente simétrica centrada en ~50 Nm, con una agrupación secundaria en ~12 Nm.




Figura 4: Distribución de la variable torque [Nm].

tool_wear [min]: distribución casi uniforme entre 0 y 180 minutos, con un pico anómalo y abrupto en torno a 200-210 minutos.




Figura 5: Distribución de la variable tool_wear [min].

product_type: marcado desbalance: tipo "L" > 10.000 registros; tipo "M" ~2.800 registros; tipo "H" ~1.500 registros. El tipo "L" representa la mayoría de la producción.




Figura 6: Distribución de la variable product_type.

target: balance casi simétrico con leve predominancia de “failure” (~7.400 registros) sobre “normal” (~7.000 registros).




Figura 7: Distribución de la variable target.

3.4 Proporciones

Se analizaron las proporciones de las variables categóricas mediante gráficos de torta:




Figura 8: Gráficos de torta de las variables product_type y target.

Proporción de product_type: “L” representa el 71,4% del total, “M” el 18,5% y “H” el 10,1%. Esta distribución refleja que la producción está dominada por el tipo de producto “L”, mientras que los otros dos tipos, “M” y “H”, son mucho menos frecuentes.

Proporción de target: 51,5% de los registros corresponden a fallas y 48,5% a operación normal. El dataset se encuentra casi equilibrado en términos absolutos (el ligero desbalance fue corregido más adelante).

También se analizó la distribución de fallas según el tipo de producto:




Figura 9: Distribución de fallas por tipo de producto.

Distribución de fallas por tipo de producto (análisis cruzado):

Tipo de producto	% Normal	% Fallas	Observación
Tipo L	59,83	40,17	El más confiable. Al ser el tipo más producido, su baja tasa de fallas relativa es favorable para el sistema.
Tipo M	20,4	79,6	Mayor tasa de fallas del conjunto. Opera frecuentemente fuera del rango seguro de los sensores.

Tipo de producto	% Normal	% Fallas	Observación
Tipo H	49,93	50,07	Comportamiento casi aleatorio (50/50), lo que indica alta sensibilidad a cualquier variación en las condiciones de operación.

Tabla 4: Distribución de la variable target según tipo de producto.

El tipo “M” presenta la mayor tasa relativa de fallas. Esto puede deberse a que los equipos que fabrican este tipo de producto operan bajo condiciones más exigentes (mayor torque, mayor temperatura de proceso), lo que los hace más susceptibles a fallas.

3.5 Relaciones entre variables y gráficos de dispersión

Se analizaron las relaciones entre variables mediante un mapa de calor de correlaciones y gráficos de dispersión.




Figura 10: Correlación entre las variables del conjunto de datos.




Figura 11: Gráfica de correlación y distribución según etiquetas de falla (verde) y funcionamiento normal (azul).

Se presenta el análisis de los pares de variables más relevantes para la detección de fallas:

air_temp (distribución por target): mientras que las operaciones normales (azul) se distribuyen de forma más uniforme en el rango medio, las fallas (verde) presentan una concentración significativamente mayor y un pico de densidad claro cerca de los 304K, lo que sugiere que las temperaturas elevadas son un factor de riesgo o un indicador clave para predecir anomalías en el sistema.




Figura 12: Distribución de la temperatura del aire para ambos estados de operación (“falla” vs. “normal”).

speed (distribución por target): la velocidad también diferencia bien las clases. La operación normal se mantiene estable entre 1200-1800 RPM (rango predominantemente seguro), mientras que las fallas muestran una concentración en torno a 2700 RPM (velocidad muy alta). También se observa una mayor densidad de fallas hacia los valores inferiores del rango, aunque dentro de él, lo que sugiere que la velocidad baja es un factor de riesgo cuando se combina con *torque* elevado más que de forma aislada.




Figura 13: Distribución de la velocidad para ambos estados de operación (“falla” vs. “normal”).

torque (distribución por target): el torque es el mejor diferenciador individual de fallas. Las distribuciones de operación normal y falla están claramente desplazadas: los casos normales se

concentran en el rango 30-55 Nm, mientras que las fallas se asocian principalmente a torques elevados (> 60 Nm) y también a torques muy bajos (< 15 Nm). Esta bimodalidad en fallas sugiere dos mecanismos distintos de avería.




Figura 14: Distribución del torque para ambos estados de operación (“falla” vs. “normal”).

tool_wear (distribución por target): existe una concentración notable de fallas en valores de desgaste superiores a 200 minutos. El pico anómalo observado en el histograma de *tool_wear* coincide con una mayor tasa de fallas, lo que sugiere que pasado ese umbral de desgaste acumulado la herramienta necesita reemplazo obligatorio.




Figura 15: Distribución del desgaste de la herramienta para ambos estados de operación (“falla” vs. “normal”).

speed vs. torque (correlación: -0,82): fuerte correlación negativa (relación inversamente proporcional). A mayor torque exigido, menor velocidad de rotación, lo cual es consistente con la física de motores eléctricos. Las fallas (verde) se concentran en los dos extremos de esta curva operativa: cuando el torque es muy alto y la velocidad baja (sobrecarga mecánica) o cuando la velocidad es máxima y el torque cae a su mínimo (posible pérdida de carga). El rango central (operación equilibrada) corresponde principalmente a funcionamiento normal. Conclusión: *torque* > 65 Nm o *speed* > 2500 RPM son zonas de riesgo crítico.




Figura 16: Relación entre velocidad y torque para ambos estados de operación ("falta" vs. "normal").




Figura 17: Relación entre torque y velocidad para ambos estados de operación ("falta" vs. "normal").

air_temp vs. process_temp (correlación: +0.86): fuerte correlación positiva que confirma que el calor ambiental influye directamente en la temperatura del proceso. Sin embargo, ambas clases (“normal” y “failure”) se distribuyen de forma muy similar a lo largo de toda la nube de puntos, sin zonas de concentración diferenciadas. Esto indica que este par de variables por sí solo no permite discriminar fallas, siendo más útil como contexto operativo que como predictor directo.




Figura 18: Relación entre temperatura del aire y temperatura del proceso para ambos estados de operación (“falla” vs. “normal”).

3.6 Análisis de correlación

El mapa de calor de correlaciones entre variables numéricas (excluyendo identificadores) reveló los siguientes patrones:

Par de variables	Correlación	Interpretación
air_temp ↔ process_temp	+0,86	Fuerte correlación positiva. El calor ambiental eleva la temperatura del proceso.
speed ↔ torque	-0,82	Fuerte correlación negativa. Relación física inversa: más torque = menos velocidad.
air_temp ↔ speed	-0,10	Correlación despreciable.
air_temp ↔ torque	+0,12	Correlación muy débil.
air_temp ↔ tool_wear	-0,06	Sin relación significativa.

Par de variables	Correlación	Interpretación
process_temp ↔ tool_wear	-0,01	Sin relación significativa.

Tabla 5: Resumen de correlaciones entre variables numéricas.

4. Parte 2 - Preprocesamiento de datos

4.1 Análisis y eliminación de variables irrelevantes

Las columnas *idx* y *parent_device_id* fueron eliminadas del conjunto de datos previo al entrenamiento. Se trata de identificadores únicos o administrativos que no aportan información semántica ni patrones estadísticos al fenómeno del mantenimiento predictivo. Incluirlas podría llevar a que los modelos memoricen identidades de registros o dispositivos en lugar de aprender los patrones físicos de falla, degradando su capacidad de generalización.

4.2 Tratamiento de valores faltantes

Se encontraron 40 valores nulos en la variable *air_temp*, equivalente al 0,3% del total de registros.

Técnica utilizada: imputación por la mediana.

Se optó por la mediana (300,6 K) en lugar de la media o la eliminación de registros por las siguientes razones:

- Robustez estadística ante baja representatividad central: dado que *air_temp* presenta una distribución multimodal, ni la media ni la mediana funcionan como un centro representativo perfecto. Sin embargo, la mediana es robusta ante valores atípicos aislados y preserva el rango general de la variable sin introducir sesgos artificiales en los extremos de la distribución.
- Insignificancia del volumen de nulos: al tratarse de apenas un 0,3% de los datos distribuidos aleatoriamente, cualquier método de imputación simple tiene un impacto despreciable en la varianza global, siendo la mediana la solución estándar más eficiente y menos propensa a distorsionar las fronteras de decisión de los modelos.
- Preservación de la integridad del dataset: eliminar estos 40 registros habría significado descartar información valiosa y completamente limpia del resto de los sensores (*speed*, *torque*, *tool_wear*) en esas mismas filas, reduciendo innecesariamente el volumen del conjunto de entrenamiento.

Resultado: tras la imputación, el dataset quedó sin valores nulos en ninguna columna.

4.3 Detección y tratamiento de valores atípicos

Se utilizaron boxplots para identificar outliers. Se pueden observar outliers en las variables *process_temp*, *speed* y *torque*:




Figura 19: Boxplot de la variable *process_temp*.




Figura 20: Boxplot de la variable *speed*.




Figura 21: Boxplot de la variable torque.

Se diferenciaron dos tipos de valores atípicos:

a) Errores de sensor (valores físicamente imposibles):

Se detectaron valores de *speed* iguales o menores a cero, lo cual es físicamente imposible en una máquina en funcionamiento. Estos valores fueron imputados mediante KNN (K-Nearest Neighbors Imputer con $k=5$), aprovechando la fuerte correlación negativa entre *speed* y *torque* para estimar los valores más probables.

b) Eventos críticos (outliers con alto valor predictivo):

Se realizó un análisis de probabilidad cruzada entre los outliers estadísticos (calculados con el método $IQR: [Q1 - (1.5 \times IQR)] / [Q3 + (1.5 \times IQR)]$ y la variable *target*. Los resultados fueron determinantes:

Variable	Outliers	% Falla (outlier)	% Falla (normal)	Conclusión
torque [Nm]	Todos	100%	51,17%	El 100% de los outliers de torque coinciden con una falla. Es el indicador más directo y confiable de avería en el dataset.

Variable	Outliers	% Falla (outlier)	% Falla (normal)	Conclusión
speed [RPM]	Varios	69,52%	49,99%	La presencia de outliers en <i>speed</i> incrementa el riesgo de falla en un 39% respecto a la tasa base, pasando de ~50% a ~69,5%.
process_temp [K]	Varios	8,96%	51,72%	Los outliers de <i>process_temp</i> se asocian mayormente a operación normal (91% sin falla). No es un predictor relevante de averías.

Tabla 6: Análisis de probabilidad cruzada entre los outliers estadísticos y la variable target.

Se conservaron todos los outliers significativos (excepto los errores de sensor ya imputados). El análisis demostró que son señales predictivas fundamentales. En el caso del *torque*, el 100% de los valores atípicos coinciden con fallas, convirtiéndolo en el predictor más directo del dataset. Para *speed*, la presencia de outliers eleva la probabilidad de falla al 69,5%, un incremento del 39% respecto a la tasa base. En cuanto a *process_temp*, sus outliers se asocian mayormente a operación normal (91% sin falla), por lo que, si bien se conservan (eliminarlos no tiene un impacto significativo en el modelo dado que son pocos registros), no representan una señal de riesgo sino el comportamiento opuesto.




Figura 22: Distribución de la variable *process_temp* según la variable target.




Figura 23: Distribución de la variable speed según la variable target.




Figura 24: Distribución de la variable torque según la variable target.

4.4 Análisis de correlación para reducción de variables

Se calculó la matriz de correlación absoluta con un umbral de 0,9 para identificar pares de variables redundantes. Este valor fue elegido de forma conservadora para evitar eliminar variables que, aun siendo correlacionadas, puedan aportar señales predictivas independientes. El par con mayor correlación fue *air_temp* ↔ *process_temp* ($r = 0,86$), que quedó por debajo del umbral. Si bien este valor es elevado, ambas variables aportan información diferente al modelo: *air_temp* refleja condiciones ambientales externas y *process_temp* las condiciones internas del proceso. En consecuencia, no se eliminó ninguna variable por redundancia y el conjunto de datos mantuvo todas las columnas para el entrenamiento.




Figura 25: Matriz de correlaciones de las distintas variables.

4.5 Procesamiento de variables categóricas

product_type: se aplicó codificación one-hot, generando tres columnas binarias independientes: *product_type_L*, *product_type_M* y *product_type_H*. Esta técnica evita que el modelo asuma una jerarquía ordinal inexistente entre los tipos de producto, garantizando que cada categoría sea tratada de forma equitativa.

target: se transformó mediante codificación binaria directa: 0 = “normal”, 1 = “failure”. Esta transformación es requisito para el entrenamiento supervisado de clasificación binaria.

	air_temp [K]	process_temp [K]	speed [RPM]	torque [Nm]	tool_wear [min]	target	product_type_H	product_type_L	product_type_M
0	303.80	313.30	1406.0	52.10	166	0	0	1	0
1	302.30	311.20	1633.0	36.40	114	0	0	1	0
2	302.27	311.47	1228.0	68.75	187	1	0	0	1
3	302.35	311.93	1522.0	36.99	214	1	0	1	0
4	296.70	307.90	1743.0	27.90	55	0	0	1	0

Figura 26: Nueva disposición del conjunto de datos.

4.6 Balance del conjunto de datos

La distribución original de la variable objetivo mostraba un desbalance moderado: ~7.400 registros de falla (clase 1) vs. ~7.000 de operación normal (clase 0), lo que representa una diferencia de aproximadamente 400 muestras. Aunque el desbalance no es severo, puede inducir sesgo en modelos sensibles a la proporción de clases.




Figura 27: Balance original de la variable objetivo (target).

Técnica aplicada: over-sampling.

Se incrementó la cantidad de muestras de la clase minoritaria (normal = 0) hasta igualar la clase mayoritaria (falla = 1), duplicando aleatoriamente registros existentes de la clase minoritaria con reemplazo. Se eligió over-sampling en lugar de under-sampling para no descartar información real del dataset. El resultado fue un conjunto perfectamente balanceado con igual cantidad de muestras para ambas clases (~7.400 por clase), eliminando cualquier sesgo de proporción antes del entrenamiento.




Figura 28: Balance de la variable objetivo (target) luego de aplicar over-sampling.

4.7 Normalización del conjunto de datos

El dataset presentaba una gran disparidad de escalas entre variables: *speed* opera en rangos de miles, mientras que *torque* y *tool_wear* se miden en decenas o cientos. Sin normalización, algoritmos basados en distancias o gradientes (como la regresión logística) darían injustamente más peso a las variables numéricamente mayores.

Técnica aplicada: escalado Min-Max (normalización al rango [0, 1]).

La fórmula aplicada fue: $x' = (x - \min(x)) / (\max(x) - \min(x))$. Esta técnica fue elegida por:

- Compatibilidad con la codificación one-hot: las variables categóricas ya codificadas están en $\{0, 1\}$, por lo que llevar las numéricas al mismo rango logra homogeneidad total en la matriz de entrenamiento.
- Preservación de la distribución original: a diferencia de la estandarización Z-score, Min-Max no reduce el impacto de los outliers, los cuales son señales críticas de falla en este dataset.
- Velocidad de convergencia: garantiza que el optimizador del modelo trabaje de forma equilibrada sobre todas las variables.

Se excluyeron de la normalización las columnas binarias (*product_type_L*, *product_type_M*, *product_type_H* y *target*), aplicando el escalado únicamente a *air_temp*, *process_temp*, *speed*, *torque* y *tool_wear*.

Los boxplots post-normalización confirman que todas las variables numéricas quedaron en el rango $[0, 1]$, con sus distribuciones relativas preservadas. Se observa que *speed* mantiene su carácter concentrado en valores bajos (outliers altos) y *torque* conserva su bimodalidad, lo cual es deseable para que el modelo pueda aprender los patrones de falla asociados a esos valores extremos.




Figura 29: Boxplots de variables numéricas normalizadas.

5. Parte 2 - Entrenamiento y evaluación de modelos

5.1 División del conjunto de datos

El conjunto de datos normalizado y balanceado fue dividido en dos subconjuntos con semilla aleatoria fija para garantizar reproducibilidad:

- **Entrenamiento (70%):** ~10.360 registros. Utilizado para que los algoritmos ajusten sus parámetros internos.
- **Prueba (30%):** ~4.490 registros. Reservado para simular datos nuevos y medir el rendimiento real de los modelos, evitando sobreajuste.

La proporción 70/30 es estándar en proyectos de clasificación y garantiza suficiente volumen tanto para el entrenamiento como para una evaluación estadísticamente robusta.

5.2 Regresión logística

Descripción del modelo

La regresión logística es un modelo lineal que estima la probabilidad de pertenencia a la clase de falla (1) mediante la función sigmoide, que mapea cualquier combinación lineal de variables al intervalo $[0, 1]$. Es el modelo de referencia (baseline) de este problema: su simplicidad permite cuantificar cuánta mejora aportan los modelos más complejos.

Hiperparámetro optimizado: C (regularización)

El parámetro C controla la inversa de la fuerza de regularización. Un C pequeño impone mayor regularización (modelo más simple, más conservador), mientras que un C grande permite coeficientes mayores y modelos más flexibles. Se evaluaron 5 valores mediante búsqueda iterativa, optimizando el F1-Score sobre el conjunto de prueba:

Valor de C	F1-Score	Descripción	Selección
0,01	0,7649	Regularización muy alta (underfitting).	
0,1	0,8253	Regularización alta.	
1	0,8464	Balance neutro.	

Valor de C	F1-Score	Descripción	Selección
10	0,8480	Mejor balance precisión/recall.	ÓPTIMO
100	0,8481	Sin mejora adicional.	

Tabla 7: Búsqueda de hiperparámetros para regresión logística.

El valor óptimo $C = 10$ logró un F1-Score de 0,8480. Aumentar C por encima de este valor no aportó mejoras, indicando que el modelo lineal alcanzó su límite de capacidad representacional con los datos disponibles.

Métricas del modelo final ($C = 10$)

Clase	Accuracy	Precisión	Recall	F1-Score
Normal (0)	85%	85%	84%	84%
Falla (1)	-	84%	86%	85%

Tabla 8: Métricas del modelo regresión logística ($C=10$).

Matriz de confusión - Regresión logística




Figura 30: Matriz de confusión de regresión logística ($C=10$).

Interpretación: el modelo detectó 1.940 fallas reales correctamente (verdaderos positivos) pero omitió 326 fallas (falsos negativos). Además, generó 369 falsas alarmas (falsos positivos). El recall del 86% para la clase “falla” indica que el modelo no detecta aproximadamente 1 de cada

7 fallas reales, lo que resulta insuficiente en este contexto industrial, donde el objetivo es minimizar los falsos negativos. La naturaleza lineal del modelo no logra capturar las relaciones complejas entre los sensores.

5.3 Árbol de decisión

Descripción del modelo

El árbol de decisión es un modelo no lineal que segmenta el espacio de variables mediante reglas lógicas sucesivas (if/else), permitiendo capturar relaciones complejas y no lineales entre sensores, como la combinación crítica de alto torque con baja velocidad. Utiliza el índice de impureza de Gini para determinar las particiones óptimas en cada nodo.

Hiperparámetro optimizado: max_depth

La profundidad máxima controla la complejidad del árbol. Un árbol superficial no captura patrones complejos (underfitting), mientras que un árbol muy profundo memoriza el conjunto de entrenamiento (overfitting). Se buscó el valor óptimo que maximice el F1-Score en prueba:


max_depth	F1-Score	Descripción	Selección
3	0,8844	Árbol muy superficial (underfitting).	
5	0,9359	Captura relaciones simples.	
7	0,9474	Balance moderado.	
10	0,9538	Buena generalización.	
15	0,9594	Segmentación precisa sin sobreajuste.	ÓPTIMO

Tabla 9: Búsqueda de hiperparámetros para árbol de decisión.

La profundidad óptima fue max_depth = 15, con un F1-Score de 0,9594. A esta profundidad el modelo logra representar las reglas físicas de falla sin memorizar el ruido de los datos de entrenamiento.

Métricas del modelo final (max_depth = 15)

Clase	Accuracy	Precisión	Recall	F1-Score
Normal (0)	96%	96%	95%	96%
Falla (1)	—	95%	96%	96%

*Tabla 10: Métricas del modelo árbol de decisión (max_depth=15).***Matriz de confusión - Árbol de decisión***Figura 31: Matriz de confusión de árbol de decisión (max_depth=15).*

Interpretación: el árbol de decisión representa un salto cualitativo respecto a la regresión logística. Se detectaron 2.184 fallas reales (vs. 1.940 del modelo anterior), omitiendo sólo 82 (vs. 326). Las falsas alarmas también se redujeron de 369 a 103. El recall del 96% significa que el modelo deja pasar menos de 1 de cada 20 fallas reales, lo cual es aceptable en muchos contextos industriales.

5.4 Random Forest (modelo ensamblado)**Descripción del modelo**

Random Forest es un algoritmo de ensamble basado en la técnica de bagging. Construye y combina las predicciones de múltiples árboles de decisión entrenados sobre muestras aleatorias del dataset y subconjuntos aleatorios de variables. Esta diversidad reduce drásticamente la

varianza del modelo, evitando el sobreajuste y logrando predicciones más estables y generalizables que un árbol individual.

En el contexto del mantenimiento predictivo, esta arquitectura permite capturar simultáneamente las interacciones no lineales entre sensores (como la relación inversa *torque-velocidad*) y aprovechar de forma robusta los outliers que son señales críticas de falla.

Configuración del modelo

- `n_estimators = 100`: se entrenaron 100 árboles de decisión independientes. Es un número suficiente para estabilizar las predicciones sin incrementar excesivamente el tiempo de cómputo.
- `max_depth`: hiperparámetro optimizado mediante búsqueda iterativa.
- `random_state = 42`: semilla fija para reproducibilidad.
- Criterio de impureza: Gini (por defecto en *scikit-learn*).

Búsqueda de hiperparámetros: `max_depth`

<code>max_depth</code>	F1-Score	<code>n_estimators</code>	Selección
3	0,8901	100	
5	0,9273	100	
10	0,9550	100	
20	0,9698	100	ÓPTIMO

Tabla 11: Búsqueda de hiperparámetros para Random Forest (`n_estimators=100`).

La profundidad óptima fue `max_depth = 20`, con un F1-Score de 0,9698. A mayor profundidad, cada árbol individual puede especializarse más en los patrones de falla, y el promedio de 100 árboles compensa el overfitting individual, logrando la mejor generalización.

Parámetros del modelo final (`max_depth = 20`, `n_estimators = 100`)

Parámetro	Valor	Descripción
<code>n_estimators</code>	100	Cantidad de árboles en el bosque.

Parámetro	Valor	Descripción
max_depth	20	Profundidad máxima de cada árbol.
max_features	"sqrt"	Variables consideradas en cada partición ($\sqrt{n_features}$).
criterion	"gini"	Criterio de impureza para evaluar particiones.
min_samples_split	2	Mínimo de muestras para dividir un nodo.
min_samples_leaf	1	Mínimo de muestras requeridas en una hoja.
bootstrap	True	Muestras con reemplazo para cada árbol (bagging).
random_state	42	Semilla fija para reproducibilidad.

Tabla 12: Parámetros del modelo Random Forest ($max_depth=20$, $n_estimators=100$).

Los parámetros confirman que el modelo opera con su configuración más flexible en varios aspectos: $min_samples_split=2$ y $min_samples_leaf=1$ permiten que cada árbol crezca hasta separar incluso muestras individuales, lo que combinado con $max_depth=20$ genera árboles muy detallados. En un árbol simple esto causaría sobreajuste severo, pero el $bootstrap=True$ con 100 árboles independientes compensa ese riesgo: cada árbol ve una muestra distinta del dataset y el promedio de todos estabiliza la predicción final.

El uso de $max_features='sqrt'$ agrega una capa adicional de diversidad, ya que cada nodo evalúa solo una fracción aleatoria de las variables disponibles, evitando que todos los árboles tomen las mismas decisiones y fortaleciendo el ensamble.

Métricas del modelo final ($max_depth = 20$, $n_estimators = 100$)

Clase	Accuracy	Precisión	Recall	F1-Score
Normal (0)	97%	98%	96%	97%
Falla (1)	—	96%	98%	97%

Tabla 13: Métricas del modelo Random Forest ($max_depth=20$, $n_estimators=100$).

Matriz de confusión - Random Forest




Figura 32: Matriz de confusión de Random Forest (max_depth=20, n_estimators=100).

Interpretación: el Random Forest detectó 2.215 fallas reales (98% de recall), omitiendo sólo 51 fallas. Las falsas alarmas fueron 87, el valor más bajo de los tres modelos. Esto lo posiciona como el modelo más seguro para la monitorización industrial.

Importancia de variables

Una de las ventajas del Random Forest es su capacidad de cuantificar la importancia de cada variable en la predicción, calculada como la reducción media del índice Gini en todos los nodos donde esa variable fue utilizada para particionar:

Variable	Importancia (Gini)	Ranking
speed [RPM]	0,3129	1°
torque [Nm]	0,2800	2°
tool_wear [min]	0,1936	3°
air_temp [K]	0,0916	4°
process_temp [K]	0,0687	5°
product_type_M	0,0319	6°
product_type_L	0,0168	7°

Variable	Importancia (Gini)	Ranking
product_type_H	0,0045	8°

Tabla 14: Importancia de variables según el modelo Random Forest.




Figura 33: Importancia de cada variable en la predicción para modelo Random Forest.

speed es la variable más determinante (0,31), seguida de cerca por *torque* (0,28). Juntas explican más del 59% de la capacidad predictiva del modelo, lo cual es consistente con la fuerte correlación negativa entre ambas y con el análisis exploratorio donde las fallas se concentraban en los extremos de la curva *speed-torque*.

En tercer lugar, *tool_wear* (0,19) tiene un peso considerable, confirmando que el desgaste acumulado de la herramienta es un indicador relevante de falla.

Las temperaturas (*air_temp* de 0,09 y *process_temp* de 0,07) tienen un impacto moderado y secundario. Finalmente, el tipo de producto prácticamente no aporta poder predictivo (los tres juntos suman menos de 0,06), lo que indica que las fallas son un fenómeno de condiciones de operación y no del tipo de producción fabricada.

6. Comparación de resultados

A continuación, se presenta la tabla comparativa de rendimiento entre los tres modelos evaluados, con sus hiperparámetros óptimos:

Modelo	Accuracy	Precisión	Recall	F1-Score	Ranking
Regresión logística (C=10)	85%	84%	86%	85%	3°
Árbol de decisión (depth=15)	96%	95%	96%	96%	2°
Random Forest (depth=20, n=100)	97%	96%	98%	97%	1°

Tabla 15: Comparativa final de rendimiento entre modelos.




Figura 34: Comparativa de rendimiento entre Regresión logística, Árbol de decisión y Random Forest.

Análisis de la comparativa:

- **Regresión logística:** el modelo más simple y rápido, pero con limitaciones claras. Su naturaleza lineal no puede representar las relaciones complejas (especialmente la curva *torque-velocidad* y los umbrales de falla). Un recall del 86% significa que ~1 de cada 7 fallas pasaría desapercibida. Útil como baseline pero insuficiente para producción.

- **Árbol de decisión:** da un salto cualitativo al superar el 94% en todas las métricas. Captura exitosamente las reglas de decisión no lineales. El riesgo es el overfitting con profundidades muy grandes, aunque el control con `max_depth=15` lo mitiga. Podría ser una alternativa viable donde la interpretabilidad (visualizar el árbol) sea prioritaria.
- **Random Forest:** el mejor modelo en todas las métricas. La combinación de 100 árboles promediados reduce la varianza individual y logra el mayor recall (98%), que es la métrica más crítica en este contexto. Sólo deja pasar 51 fallas, lo que lo convierte en el modelo más seguro para la detección de averías industriales.

6.1 Selección del mejor modelo

El Random Forest (`max_depth=20`, `n_estimators=100`) es el modelo recomendado para producción por los siguientes motivos:

- Mayor recall para la clase falla (98%): minimiza los falsos negativos, reduciendo el riesgo de fallas no detectadas.
- Mejor F1-Score (97%): equilibrio óptimo entre precisión y recall.
- Mayor exactitud global (97%).
- Robustez ante overfitting gracias a la técnica de bagging.
- Capacidad de cuantificar la importancia de variables, facilitando el mantenimiento y la interpretación del modelo.
- Menor tasa de falsas alarmas que la regresión logística, evitando paradas innecesarias de producción.

7. Conclusiones finales

Las principales conclusiones son:

7.1 Sobre los datos:

- La *velocidad de rotación* es la variable más determinante del modelo. Operar fuera del rango ~1200–1900 RPM incrementa significativamente el riesgo de falla.
- El *torque* es el segundo predictor más importante y el más directo: el 100% de sus valores atípicos corresponden a fallas reales. Monitorear ambas variables en conjunto es la acción preventiva más efectiva, debido a su fuerte relación inversa.
- El *desgaste de la herramienta* muestra un umbral crítico en torno a los 200 minutos de uso acumulado, a partir del cual la tasa de fallas aumenta abruptamente. Se recomienda programar el reemplazo antes de alcanzar ese umbral.
- Las *temperaturas* tienen un impacto moderado y no permiten por sí solas discriminar fallas, siendo más útiles como contexto operativo que como predictores directos.
- El tipo de producto *M* presenta la mayor tasa relativa de fallas (79,6%), siendo el más propenso a fallar independientemente de su volumen de producción.

7.2 Sobre el preprocesamiento:

- La imputación por mediana fue adecuada para los valores faltantes de *air_temp*, dado que la mediana es robusta y preserva la distribución.
- Los outliers de *torque* y *speed* fueron conservados por ser señales predictivas críticas. Los de *process_temp* también se conservaron, aunque están asociados mayormente a operación normal, sin impacto significativo en el modelo.
- La normalización Min-Max fue la opción correcta para este problema, ya que preserva el impacto de los outliers (a diferencia de la estandarización Z-score).

7.3 Sobre los modelos:

- La regresión logística demostró las limitaciones de los enfoques lineales ante relaciones físicas complejas. Su recall del 86% es insuficiente para un sistema de monitorización industrial.

- El árbol de decisión captura exitosamente la no linealidad del problema, alcanzando el 96% de recall con una profundidad de 15 niveles.
- El Random Forest es el modelo más robusto y recomendado, con un recall del 98% y una exactitud global del 97%. Su naturaleza de ensamble reduce el riesgo de sobreajuste y garantiza mayor estabilidad ante datos nuevos.

7.4 Recomendación final:

Se recomienda implementar el modelo Random Forest ($\text{max_depth}=20$, $\text{n_estimators}=100$) en un sistema de monitorización en tiempo real, utilizando como señales de alerta prioritaria: *torque* $> 65 \text{ Nm}$, *speed* $< 1200 \text{ RPM}$ o $> 1800 \text{ RPM}$, y *tool_wear* $> 200 \text{ min}$. La combinación de estos tres indicadores cubriría la mayoría de los escenarios de falla con alta confiabilidad.

Por otro lado, si bien los umbrales individuales sirven como primera línea de defensa, la recomendación principal es disponibilizar el modelo Random Forest mediante una API en producción. Esto permitirá disparar alertas tempranas incluso cuando el *torque* y la *velocidad* estén en rangos individualmente aceptables, pero su combinación operativa sea peligrosa, aprovechando así el verdadero potencial no lineal del modelo entrenado.